GoDP: una soluzione pratica per la Differential Privacy su dati sensibili

Tesi magistrale in Ingegneria Informatica

Riccardo Barbieri

Alma Mater Studiorum – Universita di Bologna
Corso di Laurea Magistrale in Ingegneria Informatica

Relatore: Prof. Michele Colajanni Correlatore: Ing. Silvio Russo

Anno Accademico 2023/2024

Struttura della presentazione

- Problema e obiettivo
- Fondamenti DP: ε, δ, budget
- GoDP: design e uso pratico
- Validazione: difference attack
- Risultati e conclusioni

Problema e obiettivo

Problema

Anonimizzazione tradizionale fragile con informazioni ausiliarie.

Obiettivo della tesi

Rendere la Differential Privacy applicabile in modo pratico su dataset piccoli/medi.

Contributo

GoDP: CLI in Go + specifica **DPYaml** per creare release aggregate DP.

Differential Privacy in una slide

$$\Pr[\mathcal{M}(D_1) \in S] \leq e^{\varepsilon} \Pr[\mathcal{M}(D_2) \in S] + \delta$$

- $\varepsilon \downarrow \Rightarrow$ maggiore privacy, minore utilita
- δ: probabilita di eventi distintivi

Trade-off centrale: privacy vs accuratezza

GoDP: architettura e flusso

Input

- CSV
- file DPYaml

Motore

- Apache Beam + Privacy on Beam
- Operazioni: count, sum, mean
- Filtri e tipi dichiarativi

Output

- Aggregazioni DP
- Budget tracciato per operazione

Utilità

- Riduce barriera tecnica
- Estendibile con funzioni custom

Threat model (modello centralizzato)

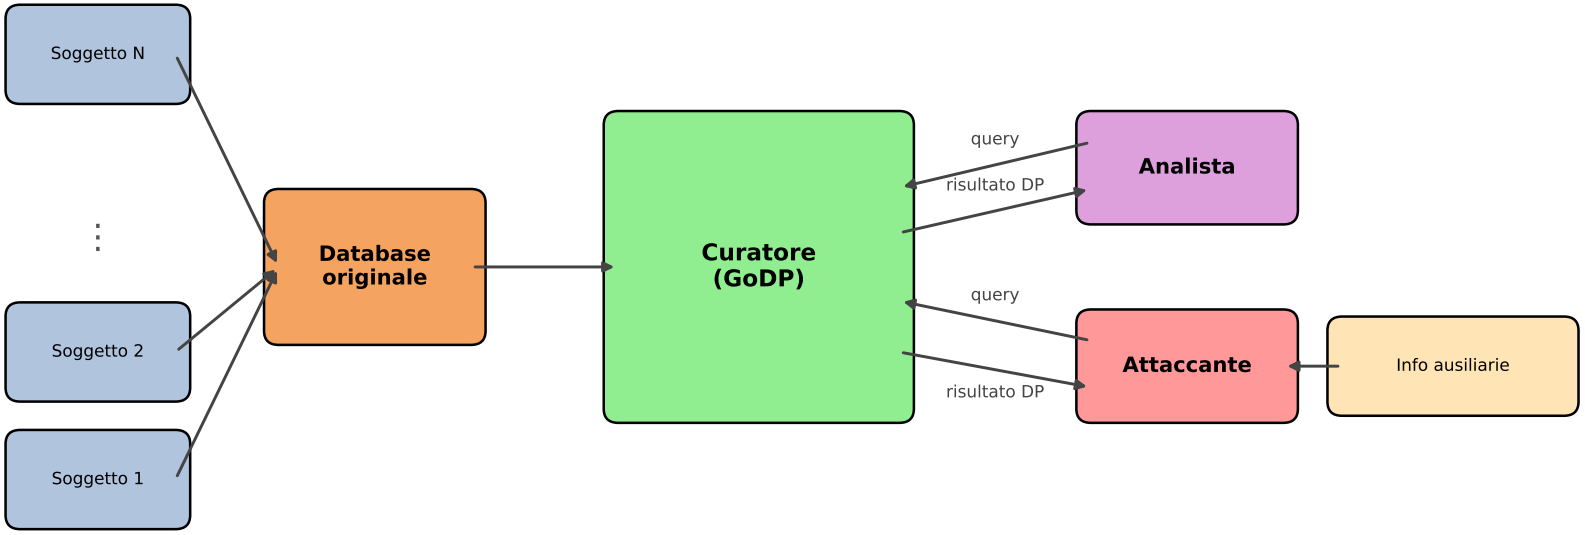

Curatore fidato, analista/attaccante con informazioni ausiliarie.

Difference attack: idea

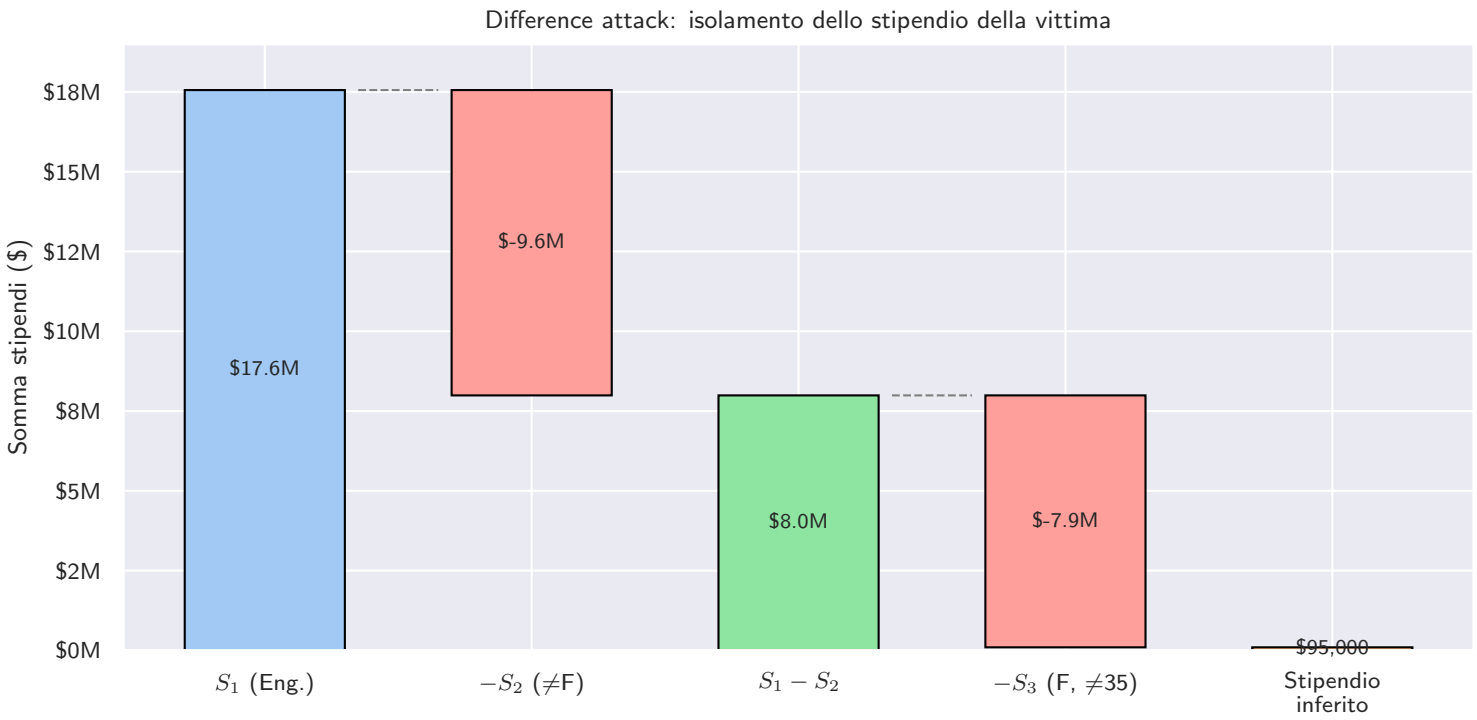

Con query aggregate e sottrazioni successive si isola il contributo della vittima.

Risultati principali dell'esperimento

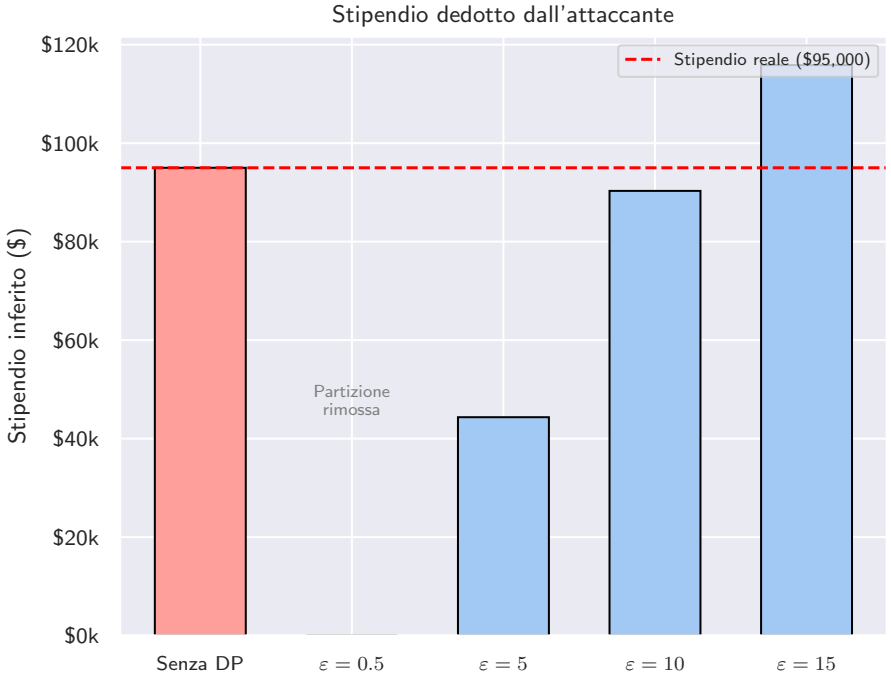

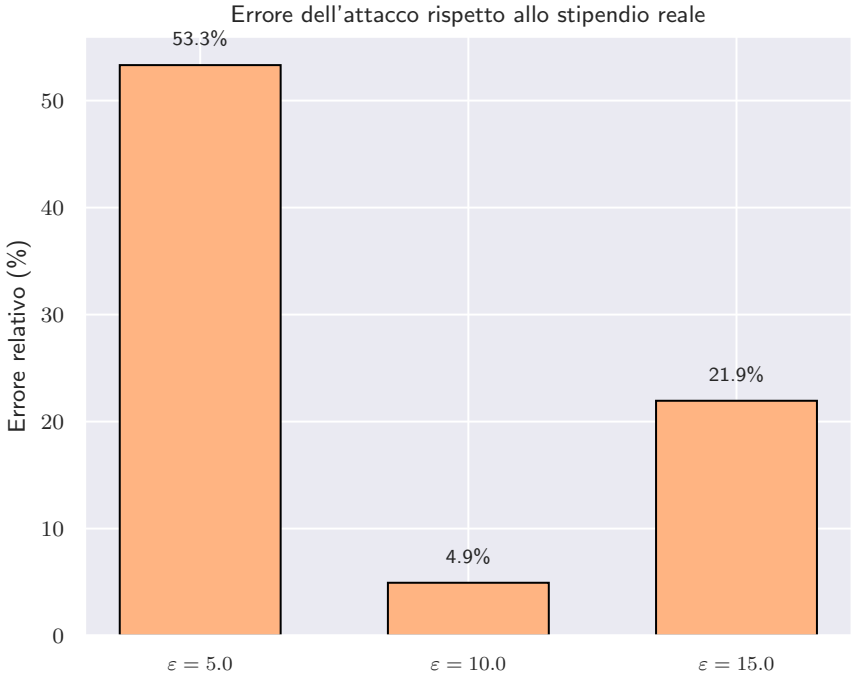

- Senza DP: attacco riuscito (stipendio esatto)
- Con DP ($\varepsilon = 0.5$): query critiche rimosse
- Con DP ($\varepsilon = 5, 10, 15$): inferenza rumorosa, precisione ridotta

Rumore e scelta di ε

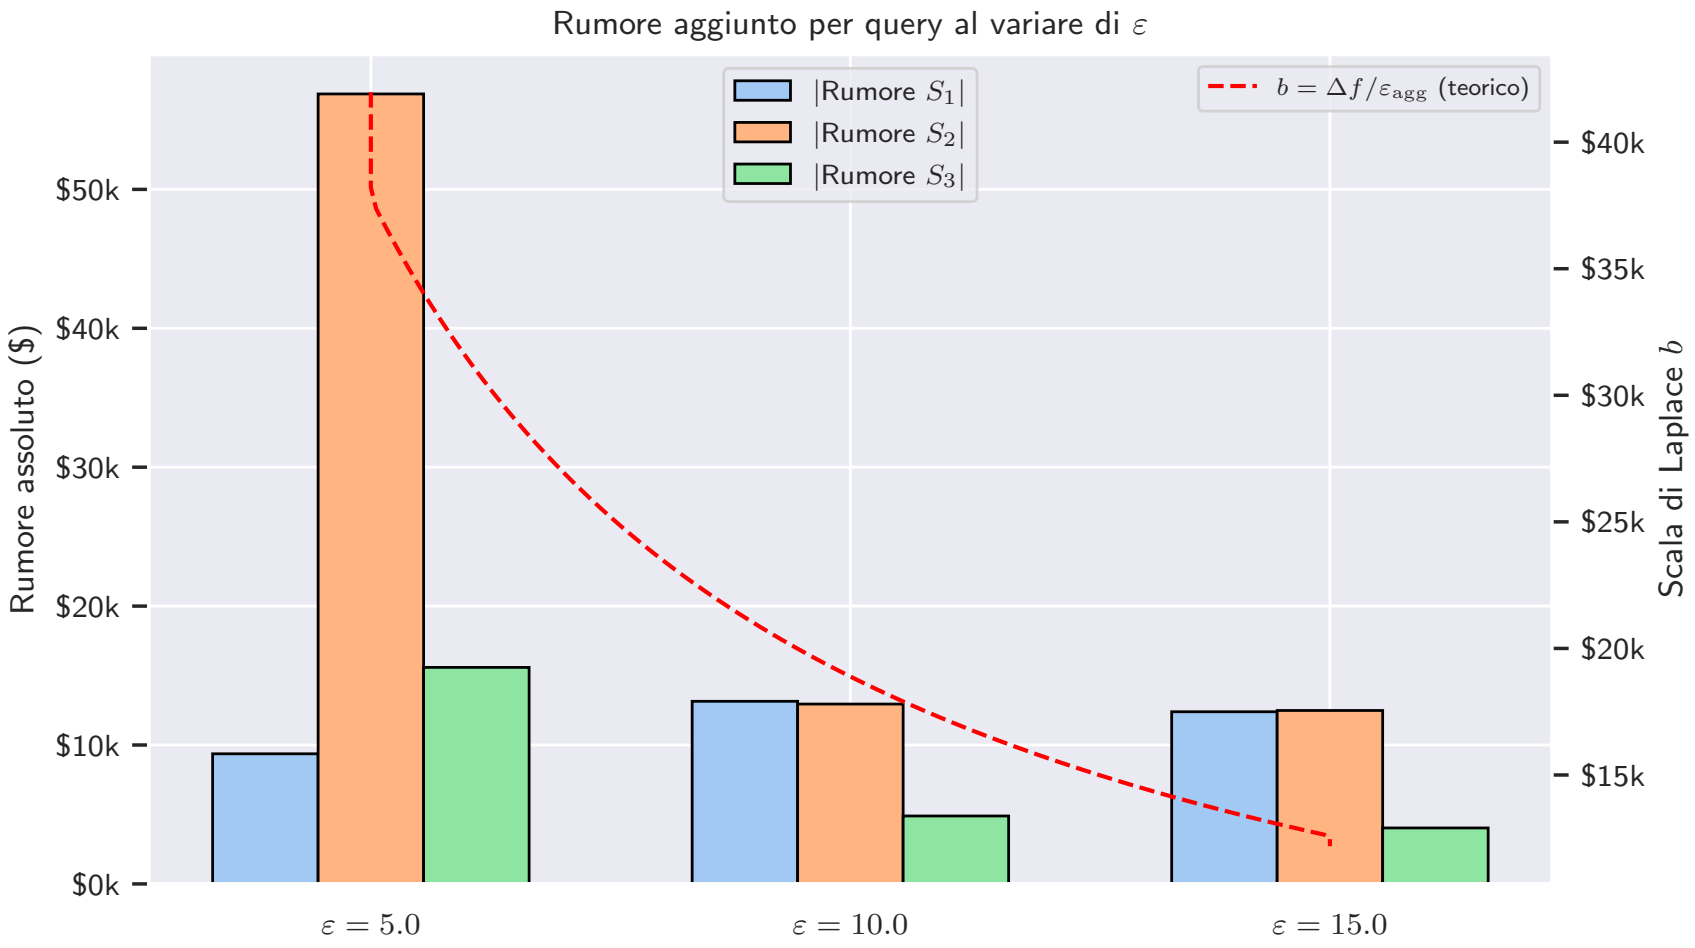

- Scala teorica: $b = \Delta f / \varepsilon_{agg}$
- Nel difference attack il rumore si compone su 3 query

Conclusioni

- GoDP rende la DP **usabile** in workflow reali
- L'esperimento conferma la protezione contro de-anonimizzazione
- La scelta di ε resta **decisione di dominio**

Sviluppi futuri

Valutazione multi-run, supporto a scenari decentralizzati, estensione operazioni.

Grazie per l’attenzione